

Informe de Aprendizaje Automático

Chavez, Mauro
a@gmail.com

Lewkowicz, Iván
a@gmail.com

Drelewicz, Santiago
a@gmail.com

Torrez, Matías
matiastorrez157@gmail.com

Culaciatì, Dante
a@gmail.com

22 de abril de 2025

Índice

1. Ejercicio 1	3
2. Ejercicio 2	3
3. Ejercicio 3	4
4. Ejercicio 4	4
5. Ejercicio 5	4
6. Conclusión	4

1. Ejercicio 1

En este inciso se pide separar los datos en conjuntos de entrenamiento y evaluación, donde no se debe utilizar la librería `train_test_split` de `sklearn`.

Primero se realizó una exploración de los datos, donde se observa que el dataset posee 200 features, todas numéricas, y 500 filas. Se observa que el dataset no tiene valores nulos y que además se trata de un problema desbalanceado, donde el 70% de los datos pertenecen a la clase 1 y el 30% restante pertenece a la clase 0, por lo que no es necesario realizar un preprocesamiento de los datos. Se decide entonces utilizar el 80% de los datos para entrenamiento y el 20% restante para evaluación.

Como la proporción de los datos es desbalanceada, realizamos un `stratified split` en la separación de los datos, procurando mantener la proporción del dataset original para los datos de entrenamiento y evaluación.

2. Ejercicio 2

Para la primera parte de este ejercicio, entrenamos un árbol de decisión con altura máxima 3 y estimamos la performance del modelo con K fold cross validation para distintas métricas. Las métricas utilizadas son *Accuracy*, *AUPRC* y *AUC ROC* y se realizó un *K-fold* con $K = 5$.

En la tabla 1 se muestran los resultados obtenidos para cada una de las 5 permutaciones de los datos, así como el promedio de cada métrica para todas las permutaciones y el resultado global, el cual se obtiene al calcular las métricas utilizando el conjunto de predicciones formado a partir de concatenar las predicciones de cada fold.

Permutación	Accuracy (training)	Accuracy (validación)	AUPRC (training)	AUPRC (validación)
1	0.8125	0.6375	0.6710	0.3225
2	0.840625	0.5875	0.7337	0.3338
3	0.825	0.6875	0.6431	0.3438
4	0.81875	0.7	0.6573	0.3625
5	0.84375	0.65	0.6958	0.4142
Promedios	0.828125	0.6525	0.6802	0.3555
Global	(NO)		(NO)	

Cuadro 1: Resultados por permutación y métricas

Se observa que este modelo presenta un buen desempeño en el conjunto de entrenamiento, pero su desempeño en el conjunto de validación es bastante bajo, lo que podría indicar que el modelo está sobreajustado a los datos de entrenamiento.

Para la segunda parte del ejercicio, se exploraron diferentes combinaciones de hiperparámetros para el modelo de árbol de decisión, utilizando `GridSearchCV` de `sklearn`. Se probaron diferentes valores para la profundidad máxima del árbol y el criterio de corte. Se utilizó `StratifiedKFold` con $K = 5$ para la validación cruzada. En la tabla 2 se muestran los resultados obtenidos para cada combinación de hiperparámetros, así como el promedio de *Accuracy* para cada combinación.

Altura máxima	Criterio de corte	Accuracy (training)	Accuracy (validación)
3	Gini	0.6375	0.6710
5	Gini	0.5875	0.7337
Infinito	Gini	0.6875	0.6431
3	Entropía	0.7	0.6573
5	Entropía	0.65	0.6958
Infinito	Entropía	0.828125	0.828125

Cuadro 2: Resultados por permutación y métricas

3. Ejercicio 3

Describa los algoritmos y técnicas de aprendizaje automático utilizados. Incluya ecuaciones relevantes y justifique sus elecciones.

4. Ejercicio 4

Presente los resultados obtenidos, como métricas de evaluación, gráficos de desempeño, etc.

5. Ejercicio 5

Analice los resultados, las limitaciones del modelo y posibles mejoras.

6. Conclusión

Resuma los hallazgos principales y las conclusiones del informe.

Referencias

Incluya las referencias bibliográficas utilizadas en el informe.